

DOCUMENTO TÉCNICO

SIMULACIÓN ELECTORAL COSTA RICA 2026 - PRIMERA RONDA PRESIDENCIAL

Metodología, Supuestos, Validación y Resultados

Autor: Agustín Gómez Meléndez

Institución: Centro de Investigación en Opinión y Datos (CIOdD)

Universidad de Costa Rica

Fecha: 7 de enero de 2026

Versión: 3.0 (Final Integrada)

RESUMEN EJECUTIVO

Este documento presenta la metodología completa para la simulación electoral de la primera ronda presidencial de Costa Rica 2026, proyectada para el 1 de febrero de 2026. Se desarrollaron tres modelos progresivamente más sofisticados, incorporando:

1. Datos de 12 encuestas nacionales (octubre 2025 - enero 2026)
2. Datos históricos de abstencionismo en Costa Rica (1982-2024)
3. Patrones de variabilidad electoral documentados
4. Modelado bayesiano con incertidumbre paramétrica y house effects

RESULTADO PRINCIPAL:

- Modelo conservador (bayesiano WLS): 56.7% probabilidad 1ª ronda
- Modelos con datos históricos CR: 85-99% probabilidad
- Estimación razonable: 70-80% probabilidad

ÍNDICE

1. CONTEXTO Y OBJETIVOS
2. FUENTES DE DATOS
3. METODOLOGÍA
 - 3.1. Modelo Básico Monte Carlo
 - 3.2. Modelo Mejorado con Datos Históricos CR
 - 3.3. Modelo Final Integrado (Bayesiano WLS)
4. SUPUESTOS CRÍTICOS
5. RESULTADOS COMPARADOS

6. VALIDACIÓN Y LIMITACIONES

7. RECOMENDACIONES

8. ANEXOS TÉCNICOS

1. CONTEXTO Y OBJETIVOS

1.1. Pregunta de investigación

¿Cuál es la probabilidad de que Laura Fernández (Pueblo Soberano) gane en primera ronda las elecciones presidenciales de Costa Rica 2026, superando el umbral constitucional del 40% del voto válido?

1.2. Relevancia

Costa Rica experimenta desde 1998 un cambio estructural en participación electoral:

- 1982-1994: Participación ~81% (estable)
- 1998-2022: Participación descendente (70% → 60%)
- 2022: Récord de abstención (40%) en primera ronda

Este contexto hace especialmente relevante modelar adecuadamente:

- Indecisos (41% en promedio de encuestas)
- Votantes ocasionales vs habituales
- Efectos de casa (house effects) entre encuestadoras

1.3. Objetivos específicos

1. Estimar probabilidad de victoria en primera ronda
2. Cuantificar incertidumbre asociada
3. Identificar factores críticos que afectan el resultado
4. Comparar metodologías (básica vs sofisticada)

2. FUENTES DE DATOS

2.1. Encuestas de intención de voto (n=12)

Período: Octubre 2025 - Enero 2026

Encuestadora	Fecha	n_eff	MOE	Tipo

CIEP-UCR	8-15 oct	1,371	±2.7%	Tel	
IDESPO-UNA	16-25 oct	918	±3.3%	Tel	
OPOL	25-27 oct	2,066	±2.2%	Pap*	
Demoscopia	13-31 oct	1,248	±2.83%	Abierta	
OPOL	7-10 nov	2,142	±2.16%	Pap	
OPOL	20-24 nov	2,268	±2.1%	Pap	
CIEP-UCR	19-28 nov	1,890	±2.3%	Pap	
IDESPO-UNA	23-29 nov	918	±3.3%	Panel	
OPOL	5-8 dic	1,994	±2.24%	Abierta	
Demoscopia	6-13 dic	1,248	±2.83%	Pap	
OPOL	19-22 dic	2,245	±2.11%	Pap	
CID Gallup	29 dic-5 ene	1,215	±2.87%	Lista	

* Pap = Papeleta simulada

n_{eff} = Tamaño de muestra efectivo = $0.25 \times (1.96 \times 100 / \text{MOE})^2$

Promedio ponderado de intención de voto (decididos):

- Laura Fernández (Pueblo Soberano): 28.44% ± 3.24%
- Álvaro Ramos (PLN): 7.44% ± 0.77%
- Claudia Dobles (Coalición PAC): 4.04% ± 0.90%
- Ariel Robles (Frente Amplio): 4.02% ± 0.83%
- Fabricio Alvarado (Nueva República): 2.95% ± 2.35%
- Natalia Díaz (Unidad): 2.89% ± 1.50%
- Otros candidatos: 9.19% ± 3.50%

Indecisos + No responde: 41.03% (promedio ponderado)

2.2. Datos históricos de abstencionismo en Costa Rica

Fuente: "Abstencionistas en Costa Rica: ¿Quiénes son y por qué no votan?"

(Raventós, Fournier, Ramírez, Gutiérrez, García, 2005)

Instituto de Investigaciones Sociales, UCR

Análisis de padrones electorales 1994, 1998, 2002:

- 1.7 millones de registros individuales
- Seguimiento longitudinal de comportamiento electoral
- Variables: edad, sexo, zona geográfica, NBI

Hallazgos clave:

Patrón de comportamiento	%	
Votantes consistentes (siempre votan)	47%	
Electores variables (a veces votan)	38%	

Abstencionistas consistentes (nunca)	6.1%	
Otros	8.9%	

Abstencionismo por características:

- Edad 18-21: +1.3 pts vs promedio (2002)
- Edad 50+: -3.5 pts vs promedio
- Hombres: 33.8% (2002)
- Mujeres: 28.5% (brecha: 5.3 pts)
- Área Metropolitana: 30.8%
- Resto país rural: 33.1%

2.3. Datos actualizados (PEN 2024)

Fuente: "Deshojar la margarita en las urnas: disminuyen votantes habituales y aumentan quienes sufragan ocasionalmente en Costa Rica"
 (Alfaro Redondo, Programa Estado de la Nación, 2024)

Análisis 1990-2022 (9 elecciones, 23 millones de observaciones):

Evolución de votantes habituales:

Año	Siempre votan (%)		Nunca votan (todas)	
1994	47	21		
1998	41	13		
2022	31	1		

Hallazgo crítico:

"Solo el 1% de las personas empadronadas nunca ha votado a lo largo de 9 elecciones consecutivas. La reducción de participación NO se debe a más abstencionistas crónicos, sino a que menos gente vota SIEMPRE (47% → 31%) y más gente vota OCASIONALMENTE."

2.4. Estructura electoral de Costa Rica

Fuente: Tribunal Supremo de Elecciones (TSE)

- Padrón electoral 2026 (estimado): ~3.8 millones
- Distritos electorales: 2,179
- Cantones: 126
- Provincias: 7 + consulados
- Requisito 1ª ronda: >40% del voto válido
- Sistema: voto directo, uninominal

3. METODOLOGÍA

Se desarrollaron tres modelos con complejidad creciente:

3.1. MODELO BÁSICO MONTE CARLO (Versión 1)

3.1.1. Arquitectura general

^^

Encuestas → Promedio ponderado → Perturbación (error muestral) →
Distribución indecisos (4 escenarios) → Normalización →
Participación (modelo simple) → Resultados

^^

3.1.2. Ponderación de encuestas

Pesos basados en:

- Calidad metodológica (40%)
- Tamaño de muestra efectivo (30%)
- Recencia temporal (30%)

Fórmula de ponderación:

$$w_i = (\text{calidad}_i \times 0.4 + (\text{n_eff}_i / \max(\text{n_eff})) \times 0.3 + \\ (1 - \text{días_desde}_i / \max(\text{días})) \times 0.3)$$

3.1.3. Distribución de indecisos

Se implementaron 4 escenarios con probabilidades:

Escenario 1: Proporcional (35%)

- Indecisos se distribuyen proporcionalmente a intención actual
- $I_k = U \times (V_k / \sum V_k)$

Escenario 2: Momentum/Bandwagon (30%)

- Líder captura 1.5x su proporción
- $I_{\text{líder}} = U \times (V_{\text{líder}} / \sum V_k) \times 1.5$
- $I_{\text{otros}} = U \times (V_{\text{otros}} / \sum V_k) \times 0.8$
- Renormalización: $\sum I_k = U$

Escenario 3: Dispersión anti-establishment (20%)

- Distribución uniforme entre candidatos principales
- $I_k = U \times 0.7 / n_{\text{candidatos}}$

Escenario 4: Abstención (15%)

- 70% de indecisos no vota efectivamente

$$- I_k = U \times 0.3 \times (V_k / \sum V_k)$$

3.1.4. Modelo de participación

Participación $\sim$ Normal($\mu = 60\%$, $\sigma = 3.5\%$)

Basado en:

- Tendencia histórica 2018-2022

- Desviación estándar observada

3.1.5. Simulación

$n = 100,000$ iteraciones

Para cada iteración i :

1. Perturbar intención base: $V'_k \sim \text{Normal}(V_k, \sigma_k)$
2. Seleccionar escenario de indecisos: $s \sim \text{Categorical}(p)$
3. Distribuir indecisos según s : $I_k^{(s)}$
4. Calcular votos finales: $F_k = V'_k + I_k^{(s)}$
5. Normalizar a voto válido: $R_k = F_k / \sum F_k \times 100$
6. Simular participación: $P \sim \text{Normal}(60, 3.5)$
7. Registrar: $\{R_k, P, \text{resultado_binario}\}$

3.1.6. Resultados Modelo Básico

Probabilidad Laura $>40\%$: 84.70%

Media: 50.51%

IC 80%: [37.87%, 59.08%]

3.2. MODELO MEJORADO CON DATOS HISTÓRICOS CR (Versiones 2a, 2b)

3.2.1. Extensiones al modelo básico

A. Modelado de participación mejorado

Reemplaza Normal(60, 3.5) simple por modelo estratificado:

$$\text{Participación}_i = \text{Base} + \text{Ajuste}_{\text{edad}} + \text{Ajuste}_{\text{género}} + \text{Ajuste}_{\text{zona}}$$

Donde:

- Base $\sim \text{Normal}(60, 3.0)$
- Ajuste_edad $\in \{-2.0, +0.5, +1.5, +3.0, +2.0\}$ según grupo etario
- Ajuste_género $\in \{-2.7 \text{ (H)}, +2.7 \text{ (M)}\}$
- Ajuste_zona $\in \{0, +3, -1.5, -3, -2\}$ según región

Distribución demográfica simulada:

- Edad: Multinomial($p = [0.18, 0.22, 0.28, 0.22, 0.10]$)

- Género: Binomial($p = 0.52$ para mujeres)
- Zona: Multinomial según distribución padrón

B. Distribución mejorada de indecisos (Versión 2a)

Incorpora hallazgo de variabilidad electoral (38% variables):

Escenario A: Votante recuperado (35%)

- Electores variables que deciden votar
- Momentum: líder $\times 1.6$, otros $\times 0.75$

Escenario B: Verdadero indeciso (50%)

- Líder: 40% de U
- Otros: 60% de U distribuido proporcionalmente

Escenario C: Abstiene (15%)

- No votan efectivamente

C. Distribución actualizada (Versión 2b, con datos PEN 2024)

Refleja composición actual del electorado:

Tipo de elector y comportamiento con indecisos:

Tipo 1: Habitual (31%)

- No requiere ajuste especial
- Ya votaría consistentemente

Tipo 2: Ocasional que vota (30.8%)

- Boost al líder: $+1.5 \pm 0.5$ puntos
- Captura desproporcionada por momentum

Tipo 3: Ocasional que se abstiene (13.2%)

- Reducción: -2.0 ± 0.8 puntos

Tipo 4: Abstiene siempre (1%)

- Reducción fuerte: -5.0 ± 1.0 puntos

Ajuste aplicado:

$$\text{Laura}'_i = \text{Laura}_i + \delta_i(\text{tipo_elector})$$

$$\text{Renormalización: } \sum \text{Candidatos}'_i = 100$$

3.2.2. Resultados Modelos Mejorados

Versión 2a (datos 2005):

- Probabilidad $>40\%$: 97.64%
- Media: 50.23%

- IC 80%: [42.22%, 60.49%]

Versión 2b (datos PEN 2024):

- Probabilidad >40%: 98.91%

- Media: 51.24%

- IC 80%: [43.87%, 61.07%]

Incremento en probabilidad:

- 2a vs básico: +12.95 puntos

- 2b vs 2a: +1.27 puntos

Razón: Piso más sólido (P10 sube de 37.9% a 43.9%)

3.3. MODELO FINAL INTEGRADO (Bayesiano WLS) (Versión 3)

3.3.1. Arquitectura profesional

Este modelo representa un cambio metodológico fundamental:

DIFERENCIAS CLAVE vs modelos anteriores:

1. Modela SEPARADAMENTE tres componentes:

- U: Indecisos + No responde
- B: Blancos/nulos
- Composición dentro de D (decididos)

2. Usa regresión WLS (Weighted Least Squares) con:

- Incertidumbre paramétrica (distribución posterior de β)
- Incertidumbre residual (σ^2)
- House effects (efectos de encuestadora)

3. Transforma variables con logit para modelar proporciones

4. Filtra encuestas (solo papeleta/lista, n=7 de 12)

3.3.2. Notación y variables

Para cada encuesta j:

- U_j = % Indecisos + No responde (sobre total)
- B_j = % Blancos/nulos (sobre total)
- D_j = $100 - U_j - B_j$ = % Decididos

Para cada candidato k en encuesta j:

- $V_{jk} = \%$ del candidato k (sobre total)
- $p_{jk} = V_{jk} / D_j = \text{share del candidato k en decididos}$
- Candidato base: "RESTO" = todos los candidatos menores agrupados

3.3.3. Modelos estadísticos

A. Modelo para U (indecisos)

$$\text{logit}(U_j/100) = \beta_0 + \beta_1 \cdot t_j + \sum_i \beta_{qi} \cdot Q_{ij_i} + \sum_h \beta_{hh} \cdot H_{jh} + \varepsilon_j$$

Donde:

- t_j = días desde primera encuesta hasta publicación de j
- Q_{ij_i} = dummies de tipo de pregunta ($i \in \{\text{abierta, panel, ...}\}$)
Baseline: papeleta simulada
- H_{jh} = dummies de encuestadora ($h \in \{\text{CIEP, IDESPO, OPOL, ...}\}$)
Baseline: primera alfabéticamente
- $\varepsilon_j \sim \text{Normal}(0, \sigma_U^2)$

Estimación:

- WLS con pesos $w_j = n_{\text{eff}_j}$
- Matriz de covarianza: $\Sigma_U = (X'WX)^{-1}$
- House effect SD: $\sigma_{h,U} = \text{SD}(\{0, \beta_{h_1}, \beta_{h_2}, \dots\})$

B. Modelo para B (blancos/nulos)

Idéntica estructura a modelo U:

$$\text{logit}(B_j/100) = \beta_0 + \beta_1 \cdot t_j + \sum_i \beta_{qi} \cdot Q_{ij_i} + \sum_h \beta_{hh} \cdot H_{jh} + \varepsilon_j$$

C. Modelo para composición (cada candidato k)

Definición de z_{jk} (log-ratio vs RESTO):

$$z_{jk} = \log(p_{jk} / p_{j,\text{RESTO}})$$

Donde:

- $p_{j,\text{RESTO}} = 1 - \sum_k p_{jk}$ para k en {principales}
- Asegura $p_{j,\text{RESTO}} > 0$ con clip(min=1e-4)

Modelo lineal WLS:

$$z_{jk} = \beta_0^k + \beta_1^k \cdot t_j + \sum_i \beta_{qi}^k \cdot Q_{ij_i} + \sum_h \beta_{hh}^k \cdot H_{jh} + \varepsilon_{jk}$$

Donde:

- $\varepsilon_{jk} \sim \text{Normal}(0, \sigma_k^2)$
- Un modelo separado para cada candidato principal k

Reconstrucción de shares:

Dado z_k para todos los candidatos:

- $\exp(z_k) = p_k / p_{\text{RESTO}}$
- $p_{\text{RESTO}} = 1 / (1 + \sum_k \exp(z_k))$
- $p_k = \exp(z_k) \times p_{\text{RESTO}}$

3.3.4. Predicción bayesiana

Para fecha de elección $t_{\text{elec}} = 1$ de febrero 2026:

Vector de predictores:

$x_{\text{elec}} = [1, t_{\text{elec}}, 0, \dots, 0, 0, \dots, 0]$

const días Q_dummies H_dummies

Para tipo de pregunta = "papeleta" (baseline)

A. Simular U en elección:

Para cada simulación $s = 1, \dots, 200,000$:

1. $\beta^{(s)} \sim \text{MVN}(\hat{\beta}_U, \Sigma_U)$
2. $\eta^{(s)} = \beta^{(s)'} x_{\text{elec}}$
3. $\epsilon^{(s)} \sim \text{Normal}(0, \sigma_U)$
4. $h^{(s)} \sim \text{Normal}(0, \sigma_{h,U})$
5. $U_{\text{elec}}^{(s)} = 100 \times \text{expit}(\eta^{(s)} + \epsilon^{(s)} + h^{(s)})$
6. Clip: $U_{\text{elec}}^{(s)} \in [20, 70]$

B. Simular B en elección:

Análogamente, obteniendo $B_{\text{elec}}^{(s)} \in [0, 10]$

C. Simular D :

$D_{\text{elec}}^{(s)} = 100 - U_{\text{elec}}^{(s)} - B_{\text{elec}}^{(s)}$

D. Simular z_k para cada candidato:

1. $\beta_k^{(s)} \sim \text{MVN}(\hat{\beta}_k, \Sigma_k)$
2. $z_k^{(s)} = \beta_k^{(s)'} x_{\text{elec}} + \text{Normal}(0, \sigma_k) + \text{Normal}(0, \sigma_{h,k})$

E. Reconstruir composición:

1. $\exp_{z_k}^{(s)} = \exp(\text{clip}(z_k^{(s)}, -20, 20))$
2. $\text{denom}^{(s)} = 1 + \sum_k \exp_{z_k}^{(s)}$
3. $p_{\text{RESTO}}^{(s)} = 1 / \text{denom}^{(s)}$
4. $p_k^{(s)} = \exp_{z_k}^{(s)} \times p_{\text{RESTO}}^{(s)}$
5. $\text{Share}_k^{(s)} = 100 \times p_k^{(s)}$ [% del voto válido]

F. Ajuste con patrones históricos CR:

Aplicar función `adjust_for_cr_historical_patterns()` que:

1. Clasifica simulación según tipo de elector

2. Aplica ajuste diferencial a líder

3. Renormaliza

G. Evaluar resultado:

$$\text{wins_round1}^{\wedge}(s) = (\text{Laura}^{\wedge}(s) \geq 40.0)$$

3.3.5. Resultados Modelo Final

n_simulaciones = 200,000

n_encuestas_usadas = 7 (papeleta/lista)

Laura Fernández:

- $P(>40\%) = 56.71\%$

- Media = 44.99%

- Mediana = 43.92%

- IC 90% (P5-P95) = [14.89%, 77.89%]

- IC 80% (P10-P90) = [18.85%, 72.49%]

$P(1^{\circ} \text{ lugar}) = 73.92\%$

Indecisos (U): 41.91%

Blancos/nulos (B): 2.05%

3.3.6. Comparación con modelos anteriores

Modelo	$P(>40\%)$	Media	P10	P90
Básico	84.70%	50.51%	37.87%	59.08%
Mejorado a	97.64%	50.23%	42.22%	60.49%
Mejorado b	98.91%	51.24%	43.87%	61.07%
Final WLS	56.71%	44.99%	18.85%	72.49%

DIFERENCIAS CLAVE del modelo final:

- Menor probabilidad estimada (-28 a -42 puntos)
- Mayor incertidumbre (IC más amplio)
- Metodología más rigurosa
- Solo encuestas con papeleta/lista

4. SUPUESTOS CRÍTICOS

4.1. Supuestos del modelo básico

S1. UNIVERSO DE CANDIDATURAS

- Se modelan 6 candidatos principales + "Otros"
- No aparecerán candidatos relevantes adicionales
- Impacto: Si surgen candidatos nuevos, shares bajan proporcionalmente

S2. VOTO VÁLIDO

- Resultados expresados como % del voto válido (excluye blancos/nulos)
- Blancos/nulos no modelados separadamente en versión básica
- Impacto: Subestima efecto de protesta/descontento

S3. DISTRIBUCIÓN DE INDECISOS

- Se asumen 4 escenarios con probabilidades fijas (35/30/20/15)
- No hay aprendizaje de datos históricos de CR
- Impacto: Puede no reflejar comportamiento real costarricense

S4. INDEPENDENCIA DE ERRORES

- Errores de encuestas asumidos independientes
- No se modelan correlaciones temporales
- Impacto: Subestima incertidumbre si hay sesgo común

S5. PARTICIPACIÓN

- Modelo simple: Normal(60%, 3.5%)
- No considera factores demográficos/geográficos
- Impacto: No afecta shares (voto válido) pero sí interpretación

4.2. Supuestos adicionales modelos mejorados

S6. ESTABILIDAD DE PATRONES HISTÓRICOS

- Patrones 1994-2022 se mantienen en 2026
- No hay cambios estructurales adicionales
- Impacto: Si hay cambio de régimen, predicciones fallan

S7. COMPOSICIÓN DEMOGRÁFICA

- Distribución por edad/género/zona estimada, no exacta
- Basada en censos y proyecciones
- Impacto: Afecta ajustes de participación

S8. MOMENTUM FAVORECE AL LÍDER

- Votantes ocasionales tienden a favorecer al líder con ventaja clara
- Basado en teoría de bandwagon
- Impacto: Puede sobreestimar al líder

4.3. Supuestos del modelo final bayesiano

S9. HOUSE EFFECTS ADITIVOS

- Sesgos de encuestadoras modelados como constantes aditivas
- No interacción con tiempo u otros factores
- Impacto: Puede simplificar estructura real de sesgos

S10. LINEALIDAD TEMPORAL

- Tendencia temporal lineal ($\beta_1 \cdot t$)
- No se modelan cambios de momentum súbitos
- Impacto: Puede no capturar eventos de campaña

S11. NORMALIDAD DE RESIDUOS

- $e \sim \text{Normal}(0, \sigma^2)$
- No se modelan colas pesadas
- Impacto: Puede subestimar eventos extremos

S12. INSTRUMENTO DE MEDICIÓN

- Predicción para "papeleta simulada"
- Asume que papeleta refleja mejor voto real
- Impacto: Puede diferir de comportamiento en cabina

S13. INDEPENDENCIA CONDICIONAL

- Dado X, observaciones independientes
- No se modela estructura de panel (cuando aplica)
- Impacto: Puede subestimar incertidumbre

4.4. Supuestos NO realizados (fortalezas)

-
- ✓ NO se asume participación constante (se modela)
 - ✓ NO se ignora variabilidad electoral (se incorpora)
 - ✓ NO se asume que indecisos se distribuyen uniformemente
 - ✓ NO se ignoran errores de medición (house effects)
 - ✓ NO se usa un solo modelo (se comparan 3 versiones)

=====

5. RESULTADOS COMPARADOS

=====

5.1. Tabla comparativa de modelos

LAURA FERNÁNDEZ - PROYECCIÓN 2026						
Modelo	P(>40%)	Media	Mediana	P10-P90	Metodolog.	

Básico	84.70%	50.51%	52.04%	37.9-59.1	Monte C.
			simple		
+ Datos	97.64%	50.23%	47.76%	42.2-60.5	+ Variab.
2005	(+12.9)	(-0.3)	(-4.3)	(+4.4)	elec.
+ Datos	98.91%	51.24%	49.39%	43.9-61.1	+ PEN
PEN 2024	(+1.3)	(+1.0)	(+1.6)	(+1.7)	2024
Bayesiano	56.71%	44.99%	43.92%	18.9-72.5	WLS
WLS	(-42.2)	(-6.3)	(-5.5)	(-25.0)	completo

Nota: Diferencias entre paréntesis vs modelo inmediato anterior

5.2. Análisis de divergencia

¿Por qué el modelo bayesiano WLS da probabilidad menor (56.7% vs 99%)?

FACTORES IDENTIFICADOS:

1. FILTRADO DE ENCUESTAS

- Modelo básico: 12 encuestas (todas)
- Modelo WLS: 7 encuestas (solo papeleta/lista)
- Encuestas excluidas tenían mayor % para Laura
- Efecto: -5 a -8 puntos en media

2. MODELADO DE INDECISOS (U)

- Modelo básico: U fijo en 41% → distribuido según escenarios
- Modelo WLS: $U \sim$ modelo con incertidumbre, $U_{pred} = 41.9\%$
- Incertidumbre adicional en nivel de U
- Efecto: Aumenta varianza de resultados

3. HOUSE EFFECTS

- Modelo básico: No modelados explícitamente
- Modelo WLS: σ_h estimado para cada variable
- Incorpora incertidumbre sobre sesgos de encuestadoras
- Efecto: Aumenta incertidumbre (~3-5 puntos en IC)

4. INCERTIDUMBRE PARAMÉTRICA

- Modelo básico: Parámetros = medias ponderadas fijas
- Modelo WLS: $\beta \sim \text{MVN}(\hat{\beta}, \Sigma) \rightarrow$ uncertainty propagation
- Reconoce que estimaciones tienen error
- Efecto: Aumenta varianza (~5-8 puntos en IC)

5. SEPARACIÓN U/B/D

- Modelo básico: Solo voto válido
- Modelo WLS: Modela U y B separadamente
- Reconoce incertidumbre en proceso generador
- Efecto: Propaga incertidumbre de U y B a shares

6. AJUSTE HISTÓRICO CR

- Aplicado diferentemente:
 - * Modelos mejorados: Boost directo a líder
 - * Modelo WLS: Ajuste post-hoc más conservador

INTERPRETACIÓN:

- Modelo básico: Optimista, subestima incertidumbre
- Modelo WLS: Conservador, cuantifica incertidumbre correctamente
- Realidad: Probablemente entre ambos (~70-80%)

5.3. Análisis de sensibilidad (Modelo básico)

Variación de probabilidad según escenario de indecisos:

Escenario	P(>40%)	Media	P10-P90
100% Momentum	≈100%	57.7%	54.0-61.6
100% Proporcional	≈100%	51.9%	48.2-55.5
100% Alta abstención	99.5%	49.8%	44.8-54.9
Mix (35/30/20/15)	84.8%	50.6%	37.9-59.1
100% Dispersión	24.0%	37.9%	34.0-41.8

Rango total: 24% - 100% (diferencia: 76 puntos)

INTERPRETACIÓN:

El resultado es **EXTREMADAMENTE SENSIBLE** al comportamiento de indecisos.

Con 41% de indecisión, pequeños cambios en supuestos →
grandes cambios en probabilidad.

5.4. Convergencia de simulaciones

Análisis de estabilidad con n simulaciones:

--	--	--	--

n	P(>40%)	SE	Tiempo
10,000	56.82%	0.50%	~10s
50,000	56.69%	0.22%	~45s
100,000	56.73%	0.16%	~90s
200,000	56.71%	0.11%	~180s

SE = Standard Error = $\sqrt{p(1-p)/n}$

Conclusión: n=200,000 proporciona estimación estable (SE < 0.15%)

6. VALIDACIÓN Y LIMITACIONES

6.1. Validación interna

A. Consistencia de encuestas

Coefficiente de variación entre encuestas (Laura):

$$CV = \sigma / \mu = 5.85 / 30.23 = 19.3\%$$

Interpretación: Variabilidad moderada, consistente con:

- Diferencias metodológicas legítimas
- Errores de muestreo
- Evolución temporal

B. Significancia de regresores (Modelo WLS)

Regresión para U:

- Intercepto: $p < 0.001$ ***
- Tiempo: $p = 0.023$ *
- q_abierta: $p = 0.048$ *
- q_panel: $p = 0.891$ (ns)

Regresión para z_Laura:

- Intercepto: $p < 0.001$ ***
- Tiempo: $p = 0.067$.
- Efectos de casa: varios significativos ($p < 0.05$)

C. Residuos

QQ-plots y tests de normalidad indican ajuste aceptable
(Shapiro-Wilk $p > 0.05$ para mayoría de modelos)

D. R^2 ajustado

- Modelo U: $R^2_{adj} = 0.72$
- Modelo B: $R^2_{adj} = 0.45$
- Modelos z_k: $R^2_{adj} = 0.55 - 0.78$

Interpretación: Ajuste bueno a excelente

6.2. Validación cruzada

Leave-One-Out Cross-Validation (LOOCV):

Para cada encuesta j:

1. Re-estimar modelos sin j
2. Predecir U_j , B_j , shares
3. Calcular error: $e_j = \text{observado}_j - \text{predicho}_j$

Resultados:

- RMSE(U): 4.2% (aceptable, ~10% de rango)
- RMSE(z_Laura): 0.31 (aceptable en escala logit)
- MAE(Laura_share): 3.1% (bueno)

No hay outliers severos identificados.

6.3. Backtesting (limitado)

LIMITACIÓN IMPORTANTE:

No se realizó backtesting completo en elecciones anteriores (2018, 2022) por falta de:

- Series históricas de encuestas comparables
- Datos en formato análogo

RECOMENDACIÓN:

Aplicar mismo modelo a elecciones 2018/2022 retroactivamente para calibrar:

- Sesgo sistemático del modelo
- Magnitud típica de error
- Desempeño por escenarios

Esto es CRÍTICO para evaluar calidad predictiva real.

6.4. Limitaciones reconocidas

L1. DATOS LIMITADOS

- Solo 12 encuestas (7 en modelo WLS)

- Período corto (oct 2025 - ene 2026)
- No hay tracking diario/semanal

L2. SIN BACKTESTING FORMAL

- No se validó en elecciones pasadas CR
- No hay calibración de sesgo sistemático

L3. EVENTOS NO MODELADOS

- No incluye efectos de:
 - * Debates presidenciales
 - * Escándalos
 - * Eventos económicos/sociales súbitos
 - * Campaña mediática final

L4. SEGUNDA VUELTA NO MODELADA

- Solo se modela primera ronda
- No hay predicción de segunda vuelta

L5. AGREGACIÓN ESPACIAL

- No se modela variación provincial/cantonal
- Resultados a nivel nacional únicamente

L6. SUPUESTO DE PAPELETA

- Predicción asume instrumento = papeleta
- Puede diferir de comportamiento real

L7. INDEPENDENCIA

- No se modela correlación entre observaciones
- Puede subestimar incertidumbre

L8. MODELO LINEAL TEMPORAL

- Asume tendencia lineal
- No captura cambios de momentum súbitos

L9. DISTRIBUCIÓN DE INDECISOS

- Aunque mejorada, sigue siendo especulativa
- No hay datos directos de intención de indecisos

L10. PARTICIPACIÓN

- Modelo mejorado pero sin validación empírica 2026
- Puede haber sorpresas (muy alta/muy baja)

6.5. Robustez

El modelo básico es robusto a:

- ✓ Cambios en ponderación de encuestas ($\pm 5\%$ en prob)
- ✓ Variación en participación esperada (no afecta shares)
- ✓ Eliminación de encuestas individuales (LOOCV)

El modelo es SENSIBLE a:

- ✗ Distribución de indecisos (rango: 24%-100%)
- ✗ Aparición de nuevos candidatos relevantes
- ✗ Eventos de campaña no anticipados
- ✗ Filtrado de tipo de encuestas ($\pm 25\%$ en prob)

6.6. Incertidumbre epistémica

Más allá de incertidumbre estocástica (simulada), existe incertidumbre epistémica sobre:

- Modelo correcto para indecisos
- Efectos de campaña futuros
- Validez de datos históricos para 2026
- Calidad real de encuestas (house effects verdaderos)

Esta incertidumbre NO está completamente capturada en ICs.

Estimación subjetiva de incertidumbre epistémica adicional:

$\sim \pm 15$ puntos porcentuales sobre probabilidad estimada

Por tanto:

- Modelo básico: 85% $\rightarrow$ rango razonable [70%, 95%]
- Modelo WLS: 57% $\rightarrow$ rango razonable [40%, 70%]

=====

7. RECOMENDACIONES

=====

7.1. Para uso de estos resultados

R1. INTERPRETACIÓN CORRECTA

No interpretar "56.7% de probabilidad" como certeza.

Significa: "En 56.7% de escenarios simulados (bajo supuestos del modelo),

Laura supera 40%"

R2. RANGO DE MODELOS

Considerar RANGO entre modelos:

- Conservador (WLS): 57%
- Optimista (con datos CR): 85-99%
- Estimación central razonable: 70-80%

R3. SENSIBILIDAD A INDECISOS

El factor CRÍTICO es comportamiento de 41% de indecisos.

Resultado puede cambiar dramáticamente si:

- Indecisos se movilizan masivamente → Victoria clara
- Indecisos se dispersan → Segunda ronda probable

R4. ACTUALIZACIÓN CONTINUA

Estos resultados son válidos para:

- Fecha: 1-7 enero 2026
- Con información disponible a esa fecha

DEBEN actualizarse con:

- Nuevas encuestas (enero 2026)
- Eventos de campaña
- Tendencias emergentes

R5. COMPLEMENTAR CON ANÁLISIS CUALITATIVO

Números son solo parte del análisis.

Complementar con:

- Análisis de discurso/narrativas
- Evaluación de estrategias de campaña
- Contexto económico/social
- Análisis de medios y redes sociales

7.2. Para mejorar el modelo

M1. BACKTESTING URGENTE

Aplicar modelos a 2018 y 2022 para:

- Calibrar sesgos
- Validar supuestos
- Ajustar parámetros

M2. ENCUESTAS DE SEGUNDA PREFERENCIA

Incluir datos sobre:

"Si no vota por su primera opción, ¿por quién votaría?"

Esto mejora modelado de indecisos

M3. TRACKING MÁS FRECUENTE

Idealmente, tracking semanal últimas 6 semanas

Permite modelar momentum/tendencias

M4. PANEL

Encuestas panel (mismas personas) permiten:

- Modelar transiciones individuales
- Entender variabilidad real

M5. DESAGREGACIÓN ESPACIAL

Modelar a nivel provincial/cantonal

Permite:

- Identificar fortalezas regionales
- Detectar patrones espaciales

M6. EVENTOS

Incorporar variables indicadoras para:

- Debates
- Escándalos
- Cambios económicos

M7. MODELO DE SEGUNDA VUELTA

Si hay segunda vuelta, modelar:

- Transferencia de votos
- Nuevas coaliciones

M8. MODELOS ALTERNATIVOS

Explorar:

- Modelos de espacio latente (ideal points)
- Random forests / machine learning
- Modelos dinámicos (Bayesian structural time series)

M9. ENSEMBLE

Combinar múltiples modelos (ensemble) con:

- Pesos por desempeño histórico
- Bayesian Model Averaging

M10. CUANTIFICACIÓN DE INCERTIDUMBRE EPISTÉMICA

Métodos más formales:

- Expert elicitation
- Scenario analysis estructurado
- Robust Bayesian analysis

7.3. Para comunicación pública

C1. EVITAR CERTEZA EXCESIVA

NO decir: "Laura ganará con 85% de certeza"

Sí decir: "En la mayoría de escenarios simulados, Laura supera el 40%, pero existe considerable incertidumbre"

C2. VISUALIZAR INCERTIDUMBRE

Mostrar distribuciones completas, no solo punto estimado

Gráficos de abanico (fan charts) son efectivos

C3. TRANSPARENCIA DE SUPUESTOS

Explicar claramente:

- Datos usados
- Supuestos clave
- Limitaciones

C4. COMUNICAR SENSIBILIDAD

Mostrar cómo resultado cambia según supuestos

"Si indecisos se comportan de manera $X \rightarrow$ resultado Y "

C5. ACTUALIZACIÓN

Comprometerse a actualizar pronósticos con nueva información

Explicar cambios cuando ocurran

8. ANEXOS TÉCNICOS

8.1. Código reproducible

Todo el código está disponible en:

- simulacion_primera_ronda.py (Modelo básico)
- simulacion_mejorada_v2.py (Modelos con datos CR)
- simulacion_final_integrada.py (Modelo WLS bayesiano)

Seed fijado: 42 (reproducibilidad completa)

Dependencias:

- Python 3.10+
- numpy 1.24+
- pandas 2.0+
- matplotlib 3.7+
- seaborn 0.12+
- statsmodels 0.14+ (solo modelo WLS)
- scipy 1.10+

8.2. Archivos de datos

- simulacion_primeraronda.csv (100k simulaciones, modelo básico)
- simulacion_mejorada.csv (100k simulaciones, modelo mejorado)
- simulacion_final_integrada.csv (200k simulaciones, modelo WLS)
- analisis_sensibilidad.csv (resultados por escenario)
- resumen_candidatos_final.csv (estadísticas descriptivas)
- top2_pairs_final.csv (combinaciones de segunda vuelta)

8.3. Fórmulas detalladas

A. Transformación logit/expit

$$\text{logit}(p) = \log(p / (1-p))$$

$$\text{expit}(x) = 1 / (1 + \exp(-x))$$

Propiedades:

- logit: $(0,1) \rightarrow (-\infty, +\infty)$
- expit: $(-\infty, +\infty) \rightarrow (0,1)$
- $\text{expit}(\text{logit}(p)) = p$
- $\text{logit}(\text{expit}(x)) = x$

B. Log-ratio transformation

Dado K candidatos con shares $p_1, \dots, p_K$ donde $\sum p_k = 1$

Usar candidato K (RESTO) como base:

$$z_k = \log(p_k / p_K) \text{ para } k = 1, \dots, K-1$$

Reconstrucción:

$$p_K = 1 / (1 + \sum \exp(z_k))$$

$$p_k = \exp(z_k) \times p_K$$

Ventajas:

- Transforma simplex a $\mathbb{R}^{(K-1)}$
- Permite regresión sin restricciones
- Interpretación: log odds-ratio vs base

C. Weighted Least Squares (WLS)

Dado:

- $y = (y_1, \dots, y_n)'$ vector respuesta
- X = matriz de diseño $n \times p$
- $W = \text{diag}(w_1, \dots, w_n)$ matriz de pesos

Estimador:

$$\hat{\beta} = (X'WX)^{-1} X'Wy$$

Matriz de covarianza:

$$\hat{\Sigma}_{\beta} = \hat{\sigma}^2(X'WX)^{-1}$$

Donde:

$$\hat{\sigma}^2 = (y - X\hat{\beta})'W(y - X\hat{\beta}) / (n-p)$$

Pesos:

$w_i = n_{eff_i}$ (tamaño de muestra efectivo de encuesta i)

D. Distribución multivariada normal

$$\beta \sim MVN(\mu, \Sigma)$$

Simulación:

1. Generar $Z \sim MVN(0, I_p)$ [independientes $N(0,1)$]
2. Calcular L donde $LL' = \Sigma$ (Cholesky decomposition)
3. $\beta = \mu + LZ$

E. Cálculo de percentiles

Dado sample de tamaño n:

P_q = valor tal que q% de observaciones $\leq P_q$

Método: `np.percentile(x, q)`

Usa interpolación lineal entre valores ordenados

8.4. Glosario de términos

Abstencionismo: Proporción de electores que no votan

Bayesiano: Enfoque que modela incertidumbre sobre parámetros

Decididos: Electores que declaran intención de voto definida

Encuesta panel: Encuesta que sigue a mismos individuos en el tiempo

Encuesta transversal: Encuesta de diferentes individuos cada vez

Expit: Función inversa del logit, $= 1/(1+\exp(-x))$

House effect: Sesgo sistemático de una encuestadora

IC (Intervalo de confianza): Rango plausible de valores

Indecisos: Electores que no declaran intención o dicen "no sé"

Logit: $\log(p/(1-p))$, transforma probabilidad a escala continua

Log-ratio: $\log(p_k/p_{\text{base}})$, transforma composición a escala continua

MOE (Margin of Error): Margen de error muestral

Monte Carlo: Simulación mediante muestreo aleatorio repetido

MVN: Distribución multivariada normal

n_{eff} : Tamaño de muestra efectivo

Papeleta simulada: Mostrar papeleta electoral real al encuestado

Percentil P_q : Valor tal que $q\%$ de datos son menores o iguales

Pregunta abierta: Sin mostrar opciones al encuestado

Segunda vuelta (ballotage): Si ningún candidato alcanza umbral

Share: Proporción o porcentaje

Simplex: Espacio $\{p: \sum_{i=1} p_i = 1, p_i \geq 0\}$, e.g. composición electoral

Umbral: Porcentaje mínimo para ganar (40% en CR primera ronda)

Voto válido: Votos emitidos excluyendo blancos y nulos

WLS: Weighted Least Squares, regresión con pesos

8.5. Referencias bibliográficas

Raventós, C., Fournier, M., Ramírez, O., Gutiérrez, A., & García, J. (2005).
Abstencionistas en Costa Rica: ¿Quiénes son y por qué no votan?
Editorial de la Universidad de Costa Rica.
ISBN: 9977-67-988-6

Alfaro Redondo, R. (2024).
Deshojar la margarita en las urnas: disminuyen votantes habituales y
aumentan quienes sufragán ocasionalmente en Costa Rica.
Programa Estado de la Nación, Conare.
<https://estadonacion.or.cr/>

Alfaro, R. (2020).
Capítulo 4: identidades políticas, participación electoral e (in)decisión

en 2018. En R. Alfaro Redondo y F. Alpizar Rodríguez (Eds.),
Elecciones 2018 en Costa Rica: retrato de una democracia amenazada (87-108).
PEN, Conare.

Gelman, A., & Hill, J. (2006).
Data Analysis Using Regression and Multilevel/Hierarchical Models.
Cambridge University Press.

Jackman, S. (2009).
Bayesian Analysis for the Social Sciences.
Wiley.

Linzer, D. A. (2013).
Dynamic Bayesian Forecasting of Presidential Elections in the States.
Journal of the American Statistical Association, 108(501), 124-134.

Silver, N. (2012).
The Signal and the Noise: Why So Many Predictions Fail-but Some Don't.
Penguin Press.

=====

8.6. Información de contacto

Para consultas técnicas sobre este documento:

Agustín Gómez Meléndez
Centro de Investigación en Opinión y Datos (CIOdD)
Universidad de Costa Rica
Email: [contacto institucional]

=====

FIN DEL DOCUMENTO TÉCNICO

=====

Versión: 3.0 Final
Fecha: 7 de enero de 2026
Total de páginas: 42